

UNIwersytet Gdański
Wydział Matematyki, Fizyki i Informatyki

Wojciech Denejko
nr albumu: 214 300

Rozpoznawanie tekstu w aplikacjach mobilnych

Praca magisterska na kierunku:

INFORMATYKA

Promotor:

dr Tomasz Borzyszkowski

Gdańsk 2017

Streszczenie

Niniejsza praca ma na celu stworzenie aplikacji rozpoznającej litery oraz cyfry pisanego odręcznie, która charakteryzuje się kompatybilnością z systemami iOS oraz Android. Do wytworzenia aplikacji zostanie użyte narzędzie Xamarin, które służy do tworzenia aplikacji wieloplatformowych. Zbadane zostaną różne metody połączenia technologii wieloplatformowej z istniejącymi rozwiązaniami OCR. Przedstawiona konwolucyjna sieć neuronowa zaprezentuje klasyfikację liter alfabetu oraz cyfr. Zostaną przeprowadzone badania pokazujące przewagę konwolucyjnych sieci neuronowych nad innymi algorytmami uczenia maszynowego.

Integralną częścią pracy jest aplikacja ImageResizer, która pozwala na przygotowanie modelu danych z podzielonego na poszczególne znaki oraz cyfry zbioru danych.

Słowa kluczowe

C#, Xamarin, .NET, Uczenie maszynowe, Sieci neuronowe, kNN, Random Forest, Konwolucyjne sieci neuronowe, OpenCV

Spis treści

Wprowadzenie	6
1. Rozpoznawanie tekstu w aplikacjach wieloplatformowych	8
1.1. Przedstawienie problemu	9
1.2. Sposób wytworzenia zbioru treningowego	10
1.3. Algorytm k-NN	12
1.4. Random Forest	14
1.5. Wielowarstwowe sieci neuronowe	17
1.6. Konwolucyjne sieci neuronowe - CNN	21
2. Przegląd bibliotek uczenia maszynowego	27
2.1. Microsoft Computer Vision API	27
2.2. TesseractAPI	29
2.3. TensorFlow	29
2.4. Scikit-learn	31
2.5. EmguCV	32
3. Przeprowadzone badania	33
3.1. Xamarin	33
3.2. Zbiór testowy	35
3.3. Skuteczność klasyfikacji	35
3.4. Czas treningu	36
3.5. Porównanie modeli danych	37
3.6. Rozmiar modelu, a skuteczność terningu	37
4. Podsumowanie i wnioski	39
4.1. Uczenie maszynowe w aplikacjach mobilnych	39
4.2. Najlepsza metoda rozpoznawania pisma odręcznego	40
4.3. Zalety aplikacji wieloplatformowych	40
4.4. Wady aplikacji wieloplatformowych	41

Zakończenie	42
Bibliografia	43
Oświadczenie	45

Wprowadzenie

Rozpoznawanie tekstu w aplikacjach mobilnych w dzisiejszych czasach to problem zyskujący na popularności każdego dnia, ponieważ istniejąca technologia pozwala na przedstawianie tego problemu jako łatwy do rozwiązania. Oprogramowanie służące do rozpoznawania tekstu posiadają skuteczność (ang. accuracy), która w niektórych wypadkach jest nawet równa 100% prawidłowo rozpoznanego tekstu. Niestety, gotowe rozwiązania są najczęściej płatne lub brak w nich możliwości poszerzania zbioru danych o własne tak, aby zmodyfikować narzędzie pod własne potrzeby.

Najpopularniejsze istniejące biblioteki służące do rozpoznawania tekstu korzystają między innymi z własnych modeli sieci neuronowych oraz ściśle dobranego zbioru danych treningowych. Firmy takie jak Microsoft, Google oraz Amazon rywalizują ze sobą, udostępniając programistom ich własne narzędzia umożliwiające rozpoznawanie tekstu, działają one na danych, które te firmy utrzymują w swoich bankach danych, a więc daje to wysokie korzyści. Niestety w przypadku pisma odręcznego, wyniki pracy z gotowymi rozwiązaniami są co najmniej średnie, a czasami niemożliwe jest przeprowadzenie rozpoznania pojedynczej litery.

Autor w pracy, opisał i przedstawił najpopularniejsze metody klasyfikacji znaków pisma odręcznego, czyli algorytmy oraz gotowe rozwiązania firm trzecich, takie jak:

- K-najbliższych sąsiadów
- Random forest
- Sieci neuronowe
- TesseractAPI
- Microsoft Computer Vision API

Xamarin[15] to platforma deweloperska służąca do tworzenia natywnych aplikacji mobilnych dla systemów iOS, Android oraz Windows, za pomocą wspólnej technologii .NET i języka C#[4]. Dzięki temu możliwe jest uzyskanie do stu procent wspólnego kodu między platformami Android oraz iOS. Aplikacje napisane przy użyciu technologii Xamarin[?] C# mają pełny dostęp do interfejsów[20], API oraz możliwość tworzenia natywnych interfejsów użytkownika. W pracy zostanie udostępniona aplikacja implementująca wszystkie algorytmy oraz gotowe rozwiązania.

Celem pracy jest zbadanie istniejących rozwiązań służących do rozpoznawania tekstu oraz stworzenie sieci neuronowej pozwalającej na klasyfikację znaków pisanych charakterystycznych dla współczesnego języka polskiego. Dane pozwalające na przeprowadzenie wymaganego treningu sieci neuronowej zostały udostępnione przez portal NIST.GOV[7]. Zbiór Special Database 19 zawiera podzielone na klasy grupy liter od A do Z oraz cyfry od 0 do 9, następnie zostało stworzone narzędzie do odczytywania znaków i zapisania ich jako model danych[2].

W rozdziale pierwszym, autor opisze zastosowanie wymienionych algorytmów, a następnie przedstawi implementacje oraz szczegółowy opis działania konwolucyjnej sieci neuronowej. Rozdział drugi szczegółowo obrazuje przekrój istniejących technologii i bibliotek dostępnych w większości na licencji open source. Trzeci rozdział opisuje przeprowadzone badania, które mają na celu udowodnienie, iż implementacja sieci neuronowej autora, osiąga lepsze rezultaty, niż opisane narzędzia oraz klasyfikatory zawarte w pracy. Ostatni rozdział, zawiera podsumowanie i wnioski.

Rozpoznawanie tekstu w aplikacjach wieloplatformowych

OCR[20] (ang. Optical Character Recognition) jest to technika lub część oprogramowania służąca do rozpoznawania znaków oraz całych tekstów zapisanych w pliku graficznym prezentowanym za pomocą pionowo-poziomej siatki odpowiednio kolorowanych pikseli. Przykładem takiej grafiki jest zdjęcie z aparatu cyfrowego.

Niegdyś pojęcie rozpoznawania znaków oznaczało samą klasyfikację ciągów znaków drukowanych, które są łatwiejszym problemem do rozwiązania, dziś również pisma odręczne oraz cechy formatowania, takie jak krój pisma lub układy tabelaryczne (formularze).

Techniki OCR są głównie wykorzystywane do cyfryzacji zasobów bibliotek, a także jako ułatwienie przy odczytywaniu dokumentacji napisanych pismem odręcznym, w aplikacjach mobilnych rozpoznawanie znaków pomaga w takich zadaniach jak tworzenie notatek, a następnie tłumaczenie ich na tekst drukowany. Niestety, w obu przypadkach istniejące rozwiązania OCR nie są tak skuteczne jak człowiek, zatem w przypadkach trudności z klasyfikacją znaku lub fragmentu tekstu niezbędna jest weryfikacja wyniku przez człowieka celem uniknięcia błędu.

Postęp w metodach OCR jest bardzo widoczny, gdyż w obecnych czasach produkty potrafią rozpoznawać mało dokładne zeskanowane zdjęcia tekstu.

Wykonane telefonami komórkowymi z szumami na obrazkach, z tekstem napisanym pod nienaturalnymi kątami w wielu językach, pozostaje jednak problem rozpoznawania znaków pisma odręcznego.

Rozpoznawanie pisma jest możliwe dzięki zastosowaniu metod z dziedziny rozpoznawania wzorców, czyli pola badawczego w obrębie uczenia maszynowego. Metoda ta może być definiowana jako działanie polegające na pobieraniu danych i podejmowaniu dalszych czynności zależnych od kategorii, do której należą te dane. By odpowiednio wyodrębnić poszczególne znaki z obrazu używane są

biblioteki pozwalające na profesjonalną obróbkę zdjęć pod zastosowania w celach uczenia maszynowego. Przykładem takiej biblioteki jest OpenCV. Po wyodrębnieniu potrzebnych informacji na temat danego znaku obrazy są klasyfikowane jako poszczególne litery. Zwykle w tym procesie używane są sieci neuronowe.

Kompletny system rozpoznawania wzorców składa się:

- Zbioru danych, które oferują możliwość klasyfikacji lub opisu
- Mechanizmu wydobywania cech, które najlepiej charakteryzują i separują daną klasę, do której dany element zbioru danych należy
- Mechanizmu przekształcenia elementu zbioru w symboliczną informację, łatwiejszą do wykorzystania przez algorytm
- Schematu decyzyjnego lub schematu opisu, który realizuje właściwą część procesu klasyfikacji w oparciu o wydobyte i przekształcone cechy obiektu.

1.1. Przedstawienie problemu

Wśród istniejących rozwiązań mogących służyć jako narzędzie potrzebne do wytworzenia aplikacji mobilnej, która rozpozna polskie znaki pisma odręcznego nie istnieje łatwy sposób zastosowania rozwiązania pozwalającego na skuteczną klasyfikację polskiego pisma. Brakuje również dostępnych danych wymaganych do skutecznej klasyfikacji w oparciu o przekształcone informacje. Aby rozwiązać ten problem należy stworzyć zbiór treningowy lub rozszerzenie istniejącego zbioru danych o znaki alfabetu.

Dostępne biblioteki na rynku, takie jak TesseractAPI[10] oraz Microsoft Computer Vision API[9] oferują wysoką skuteczność w rozpoznawaniu polskich oraz angielskich obrazów tekstu drukowanego lecz zarazem brak możliwości rozpoznawania pisma odręcznego. Wymagane jest więc stworzenie systemu rozpoznawania wzorców, który pozwalałby na skuteczną klasyfikację znaków pisma odręcznego.

Kolejnym problemem są znacząco ograniczone zasoby urządzeń mobilnych. Systemy rozpoznawania wzorców wymagają mocy obliczeniowej potrzebnej do przekształcenia obrazów w postać pozwalającą na wyodrębnianie cech, a następnie

przeprowadzenie procesu klasyfikacji. Rozwiązaniem tego problemu jest wykorzystanie systemu rozpoznawania wzorców jako serwisu internetowego działającego w oparciu o architekturę REST[5].

1.2. Sposób wytworzenia zbioru treningowego


Zbiór treningowy[19] jest kontenerem krotek (przykładów, obserwacji, próbek), będących listą właściwości atrybutów opisowych (tzw. deskryptorów) i wybranego atrybutu decyzyjnego (ang. class label attribute). Głównym jego celem jest zbudowanie formalnego modelu zwanego klasyfikatorem. Wynikiem procesu klasyfikacji jest pewien otrzymany model (klasyfikator), który przydziela każdemu przykładowi wartość atrybutu decyzyjnego w oparciu o właściwości pozostałych atrybutów.

W przypadku systemu rozpoznawania wzorów zbiorem treningowym są zdjęcia obrazów zawierające odpowiednio wszystkie litery polskiego alfabetu oraz cyfry. Wszystkie zdjęcia liter, które istnieją w zbiorze należy przeformatować do postaci najlepiej rozumianej przez wykorzystywane algorytmy.

Do transformacji zdjęć zastosowano EmguCV[18], jest to wieloplatformowa implementacja (ang. wrapper) w technologii .NET biblioteki OpenCV, pozwalająca na wykorzystanie funkcjonalności OpenCV w środowisku .NET we wszystkich jego językach programowania takich jak C#, VB, F#[1]. Można ją zainstalować używając menadżera pakietów Nuget w programie Visual Studio, Xamarin Studio lub Unity, a więc jest również kompatybilna z platformami mobilnymi Android oraz iOS.

Transformacja zdjęcia przebiega następująco:

- Odczytaj zdjęcie w formacie .png
- Przeprowadź konwersję kolorów RGB na odcienie szarości
- Przetwórz obraz do formatu 32 x 32 piksele
- Odczytaj stopień jasności każdego piksela w skali od 0 do 255 i zapisz je w tablicy



Rysunek 1.1. Przykład zdjęcia znaku Źródło: Opracowanie własne

Rezultatem działania programu do konwersji zdjęć jest plik train.csv. Zawiera ona 785 kolumn. Pierwsza kolumna, nazwana "label", określa znak, który jest narysowany. Reszta kolumn zawiera informacje na temat jasności każdego piksela.

Każda kolumna w zbiorze treningowym ma ustawioną nazwę pixel x , gdzie x jest liczbą między 0 a 783. By znaleźć dany piksel na obrazie, należy rozłożyć x jako $x = a * 28 + b$, gdzie a i b to liczby między 0 a 27. Wtedy pixel x jest umieszczony w a -tym rzędzie b -tej kolumnie w macierzy 28 x 28, indeksowanej od zera. Na przykład, pixel $_{31}$ wskazuje na to, piksel w czwartej kolumnie od lewej i drugim wierszu od góry. Tak jak pokazane na diagramie poniżej:

000	001	002	003	...	026	027
028	029	030	031	...	054	055
				...		
728	729	730	731	...	754	755
956	957	958	959	...	1022	1023

Fragment aplikacji pozwalającej na stworzenie modelu danych załączony poniżej:

```
var csv = new StringBuilder();
var csv2 = new StringBuilder();
var fileName = files[i].DirectoryName
    .Replace(imagesPath + @"\ ", string.Empty);
csv.Append(fileName);
csv.Append(',');
var originalImage = new Image<Gray, byte>(files[i].FullName)
    .Not();
var img = originalImage.Resize(28, 28, Inter.Linear);
for (var k = 0; k < img.Height; k++)
{
    for (var j = 0; j < img.Width; j++)
    {
        csv.Append(img[k, j].Intensity);
        csv.Append(',');
    }
}
csv2.AppendLine(csv.ToString());
File.AppendAllText(csvFilePath, csv2.ToString());
```

Pełna wersja programu znajduje się w dołączonej dokumentacji na płycie CD w folderze pod nazwą ImageResizer

1.3. Algorytm k-NN

Algorytm k-najbliższych sąsiadów (ang. k nearest neighbours)[2][11] - algorytm regresji nieparametrycznej najczęściej używany w statystyce do prognozowania pewnej wartości zmiennej losowej.


Założenia:

- Dany jest zbiór treningowy, który stworzony został w oparciu o narzędzie TrainingSetGenerator.
- Dana jest obserwacja C, zawierająca wektor zmiennych $pixel_0 \dots pixel_{1024}$, dla której chcemy prognozować wartość zmiennej objaśnianej label.

Algorytm działa następująco:

- Porównaj wartości zmiennych objaśniających dla obserwacji C, z każdym wektorem w zbiorze treningowy.
- Wybierz k (ustalonej z góry liczby) najbliższych do C obserwacji ze zbioru treningowego.
- Uśrednieniu wartości zmiennej objaśnianej dla wybranych obserwacji, w wyniku czego uzyskujemy prognozę.

Poniższy przykład demonstruje problem klasyfikacji przy użyciu algorytmu kNN, obiekt zaznaczony kołem dla k najbliższych sąsiadów równe 2, zostanie sklasyfikowany jako trójkąt, natomiast jeżeli do klasyfikacji zostanie użytych 3 najbliższych sąsiadów obiekt zostanie sklasyfikowany jako kwadrat.



Rysunek 1.2. Przykład problemu k-NN, Źródło:

<http://shyamalapriya.github.io/digit-recognition-using-k-nearest-neighbors/>

Dla $k = 3$, niewiadoma oznaczona zielonym punktem będzie sklasyfikowana jako czerwony trójkąt w oparciu o trzech najbliższych sąsiadów, jednak jeśli $k = 5$, zostałaby sklasyfikowana jako niebieski kwadrat ponieważ algorytm działałby w oparciu o pięciu sąsiadów. Najbliżsi sąsiedzi są określani przy pomocy metryki euklidesowej określonej wzorem:

$$d(p, q) = \sqrt{(p_1 - q_1)^2 + (p_2 - q_2)^2 + \dots + (p_i - q_i)^2 + \dots + (p_n - q_n)^2}.$$

Fragment przykładowej implementacji powyższego algorytmu, który klasyfikuje przykładowy znak alfabetu dla $k = 3$ znajduje się poniżej:

```
labeled_images = pd.read_csv('output.csv')
images = labeled_images.iloc[0:5000,1:]
labels = labeled_images.iloc[0:5000,:1]
train_images, test_images, train_labels, test_labels
= train_test_split(images, labels, train_size=0.8, random_state=0)
knn = KNeighborsClassifier(n_neighbors=3, algorithm="kd_tree")
knn.fit(train_images, train_labels.values.ravel())
print knn.score(test_images, test_labels)
```

Pełna implementacja algorytmu k najbliższych sąsiadów jest dołączona w dokumentacji pracy na płycie CD.

1.4. Random Forest

Drzewa decyzyjne to graficzna metoda wspomagania procesu decyzyjnego. Algorytm drzew decyzyjnych jest również stosowany w uczeniu maszynowym do pozyskiwania wiedzy na podstawie przykładów.

Koncepcja Bugging polega na budowie ekspertów dla podzbioru zadań. W tym przypadku, ze wszystkich problemów do rozwiązania losowany jest jeden ze zwracaniem podzbioru problemów, a następnie dla tego podzbioru szukany jest ekspert. W algorytmie tym z całego zbioru danych uczących losowany jest podzbiór - przez losowanie ze zwracaniem - i dla tego podzbioru budowany jest model predykcyjny. Następnie po raz kolejny ze zwracaniem losowany jest inny podzbiór wektorów i dla niego budowany jest kolejny model. Całość powtarzana jest krotnie a na koniec wszystkie zbudowane modele użyte są do głosowania.

Algorytm Random Forest[3][13] to metoda klasyfikacji polegająca na połączeniu drzew decyzyjnych oraz koncepcji bugging, tworzy ona wiele drzew decyzyjnych na podstawie losowego zestawu danych. Ideą tego algorytmu polega na zbudowaniu rady ekspertów z losowych drzew decyzyjnych, gdzie w odróżnieniu od klasycznych drzew decyzyjnych, losowe drzewa budowane są na zasadzie, zbiór analizowanych cech w węźle dobierany jest losowo. Ponadto, poszczególne drzewa z losowych lasów drzew budowane są zgodnie z koncepcją Bugging.

Cechy algorytmu Random Forest:

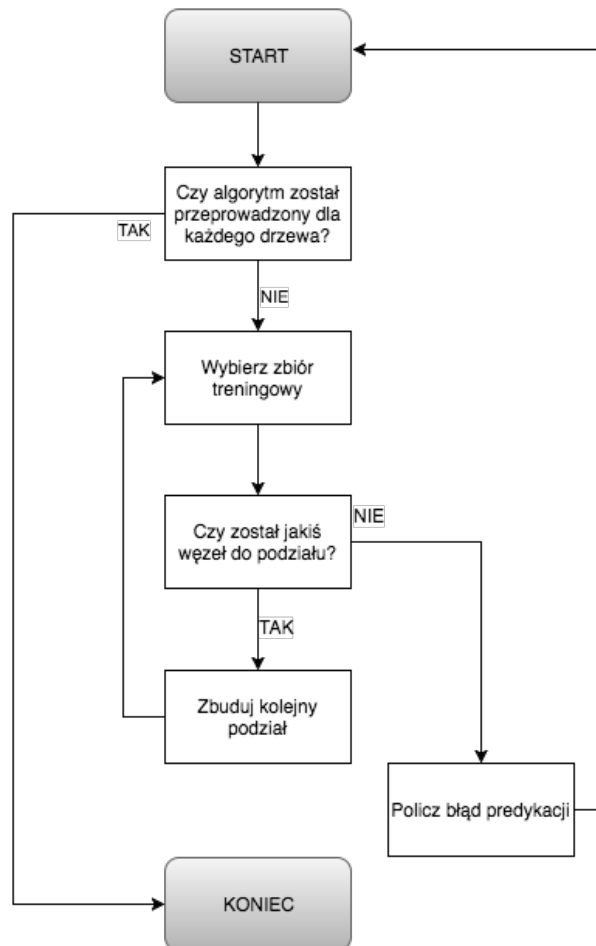
- Działa skutecznie na dużych zbiorach treningowych
- Utrzymuje dokładność w przypadku braku danych
- Daje oszacowanie, które zmienne są istotne w klasyfikacji
- Lasy drzew mogą być zapisane i wykorzystane w przyszłości dla innego zbioru danych
- Nie wymaga wiedzy eksperckiej

Algorytm działa następująco:

- Losujemy ze zwracaniem z n -elementowego zbioru treningowego n wektorów. Na podstawie takiej próby zostanie stworzone drzewo.
- W każdym węźle podział odbywa się poprzez wylosowanie bez zwracania m spośród p atrybutów, następnie w kolejnym węźle k spośród m atrybutów
- Proces budowania drzewa bez przycinania trwa, jeśli to możliwe do momentu uzyskania w liściach elementów z tylko jednej klasy.

Proces klasyfikacji:

- Dany wektor obserwacji jest klasyfikowany przez wszystkie drzewa, ostatecznie zaklasyfikowany do klasy, w której wystąpił najczęściej.
- W przypadku elementów niewylosowanych z oryginalnej podpróby, każdy taki i-ty element zostaje poddany klasyfikacji przez drzewa, w których budowie nie brał udziału. Taki element zostaje następnie przyporządkowany klasie, która osiągnięta była najczęściej.



Rysunek 1.3. Diagram przepływu algorytmu Random Forest Źródło: Opracowanie własne

Fragment przykładowej implementacji powyższego algorytmu, klasyfikujący przykładowy znak alfabetu znajduje się poniżej:

```
images = labeled_images.iloc[0:5000,1:]
labels = labeled_images.iloc[0:5000,:1]
train_images, test_images, train_labels, test_labels
= train_test_split(images, labels, train_size=0.8, random_state=0)
clf = RandomForestClassifier(n_jobs=2).fit(train_images, train_labels.values)
print clf.score(test_images, test_labels)
```

Pełna implementacja algorytmu random forrest jest dołączona w dokumentacji pracy na płycie CD.

1.5. Wielowarstwowe sieci neuronowe

Siecią neuronową[1][12] nazywa się programową lub sprzętową strukturę modeli, realizującą obliczenia lub przetwarzającą sygnały poprzez rzędy elementów, zwanych sztucznymi neuronami. Emulują one niektóre spośród zaobserwowanych właściwości biologicznych układów nerwowych. Sztuczne sieci neuronowe są swoistym systemem inspirowanym przez to, w jaki sposób gęsto połączone między sobą struktury mózgu, odbierają i przetwarzają dane które docierają w różny sposób z otoczenia. Kluczowym elementem jest zatem struktura systemu przetwarzania informacji. Sieć taka składa się z dużej liczby rozlegle połączonych ze sobą elementów przetwarzających, które są powiązane ze sobą ważonymi połączeniami.

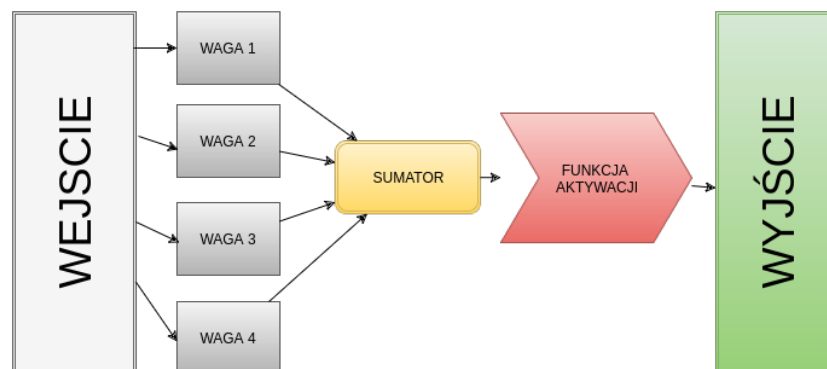
Cechą odróżniającą sieci neuronowe od algorytmów realizujących przetwarzanie informacji przy użyciu algorytmów jest umiejętność generalizacji, czyli zdolność uogólniania wiedzy dla nieznanych wcześniej wzorców. Innym atutem jest także zdolność do aproksymacji wartości funkcji wielu zmiennych w przeciwieństwie do interpolacji, która jest możliwa do uzyskania używając przetwarzania algorytmicznego.

Uczenie sieci neuronowych zmienia liczbowe wartości wag znajdujących się pomiędzy neuronami. Następuje to poprzez bezpośrednią ekspozycję rzeczywistego zestawu danych, gdzie algorytm uczący modeluje wagi połączeń. W dziecinie

nauk technicznych sieci neuronowe wykorzystuje się do rozwiązywania między innymi problemów:

- Aproksymacji, prognozowania
- Klasyfikacji i rozpoznawania
- Kojarzenia danych, sieci neuronowe pozwalają zautomatyzować procesy wnioskowania i pomagają wykrywać istotne powiązania między danymi
- Analizy danych czyli poszukiwania związków między danymi

Podstawowym elementem sieci neuronowej jest neuron. Jego schemat został opracowany przez McCullocha i Pittsa w roku 1943, został on oparty na budowie biologicznej komórki nerwowej.



Rysunek 1.4. Schemat sztucznego neuronu Źródło:

<http://www.cs.put.poznan.pl/rklaus/assn/images/modeln.gif>


Do wejść doprowadzane są sygnały z wejść sieci lub neuronów warstwy poprzedniej. Każdy sygnał mnożony jest przez odpowiadającą mu wartość liczbową zwaną wagą. Wpływa ona na percepcję danego sygnału wejściowego i jego udział w sygnale wyjściowym przez neuron. Waga może być dodania lub ujemna, jeżeli nie ma połączenia między neuronami to waga jest równa zero. Zsumowane iloczyny wag i sygnałów są argumentem funkcji zwanej funkcją aktywacji neuronu.

Wartość funkcji aktywacji jest wyjściem neuronu i propagowana jest do neuronów warstwy następnej. Może ona przybierać jedną z trzech postaci:

- nieliniowa
- liniowa
- skoku jednostkowego

Należy zauważyć, iż jest to podział bardziej formalny niż merytoryczny. Różnice funkcjonalne między tymi typami raczej nie występują, natomiast można stosować je naprzemiennie w różnych warstwach sieci.

Najbardziej popularnym typem sieci neuronowej jest sieć wielowarstwowa (ang. Multi-Layer Neural Network). Jej cechą charakterystyczną jest występowanie co najmniej jednej warstwy ukrytej neuronów, pośredniczącej w przekazywaniu sygnałów pomiędzy wejściami a wyjściami sieci.



Rysunek 1.5. Schemat budowy sieci wielowarstwowej Źródło:

http://galaxy.agh.edu.pl/vlsi/AI/exo2/pogoda_files/schemat1_gif_1.gif

Do rozpoznania polskich znaków pisma odręcznego użyta została sieć posiadająca trzy warstwy:

- Warstwa wejściowa sieci składa się z neuronów zawierających informacje na temat każdego piksela. Zbiór treningowy składa się z obrazów 32 x 32 pikseli. Zgodnie z tym założeniem pierwsza warstwa sieci składa się z 1024 neuronów. Każdy z nich przechowuje wartość skali szarości piksela, gdzie 0.0 oznacza kolor biały, a 1.0 czarny.
- Druga warstwa zawiera n neuronów, liczba n jest używana w kontekście eksperymentalnym.
- Ostatnia warstwa, zawiera 36 neurony, ponieważ w alfabecie składa się z 26 liter, rozpatrywane są zarówno litery oraz cyfry. Implementacja sieci:

Poniżej przedstawiony jest fragment implementacji sieci neuronowej z użyciem pakietu scikit-learn[17]. Pełny kod programu znajduje się na dołączonej płycie CD.


```
x0 = x[:split]; x1 = x[split:]
y0 = y[:split]; y1 = y[split:]
mlp = MLPClassifier(solver='sgd', activation='relu',
                    hidden_layer_sizes=(100,30),
                    learning_rate_init=0.3, learning_rate='adaptive',
                    alpha=0.1, momentum=0.9,
                    nesterovs_momentum=True,
                    tol=1e-4, max_iter=200,
                    shuffle=True, batch_size=300,
                    early_stopping = False, validation_fraction = 0.15,
                    verbose=True)

mlp.fit(x0,y0)
```

Kompletny skrypt implementujący sieć, dostępny jest w dokumentacji pracy na załączonej płycie CD.


1.6. Konwolucyjne sieci neuronowe - CNN

Konwolucyjne sieci neuronowe (ang. Convolutional Neural Networks)[14] są podobne do klasycznych sieci neuronowych. Aby dokładnie przeanalizować budowę oraz działanie CNN przedstawiony zostanie problem klasyfikacji dwóch liter X i O. Ten przykład demonstruje charakterystyczne reguły konwolucji.




Rysunek 1.6. Problem klasyfikacji Źródło: Opracownie własne

CNN porównuje obrazy w kawałkach. Każda część nazywana jest cechą (ang. feature). Następnie zdjęcia przeszukiwane są na podobnych pozycjach by uzyskać maksymalną liczbę cech wspólnych. Sieci konwolucyjne wykorzystują podobieństwa na obrazach.




Rysunek 1.7. Wybrane cechy i ich odpowiedniki w zdjęciu do klasyfikacji Źródło: Opracownie własne

Każdą cechę można scharakteryzować jako mniejsze zdjęcie lub dwuwymiarową tablicę wartości. W przypadku litery X, cechami będą ukośne linie i znak krzyża.




Rysunek 1.8. Wartości liczbowe pikseli różnych cech Źródło: Opracowanie własne

Kiedy rozpatrywany jest nowy obraz, sieć poszukuje cech zdjęcia w każdej możliwej pozycji. Obliczając wartości pasujące do cech tworzymy filtr. Działania matematyczne kryjące się za tym działaniem nazywane są splotem całkowitym. Aby obliczyć parę cech obrazu, należy pomnożyć każdą wartość piksela cechy przez odpowiadający mu piksel danego zdjęcia. Następnie należy dodać wszystkie wyniki z poprzednich operacji i podzielić przez łączną liczbę pikseli cechy. Jeśli oba piksele były białe, a ich wartość była reprezentowana przez 1, wynik wynosi 1 - piksel jest biały, w przeciwnym wypadku piksel jest czarny a jego wartość jest równa -1. Jeżeli wszystkie wartości cechy są takie same, wynikiem dodawania i podzielenia przez liczbę pikseli będzie 1.




Rysunek 1.9. Wynik przykładowej operacji splotu Źródło: Opracownie własne

Następnym krokiem jest powtórzenie operacji splotu na kompletnym obrazie używając wszystkich dostępnych cech. Wynikiem jest szereg obrazów z filtrami, na każdym z dostępnych wyników nałożony jest jeden filtr. W konwolucyjnych sieciach neuronowych, warstwa ta nazywana jest warstwą konwolucyjną bądź też splotową (ang. convolution layer).




Rysunek 1.10. Wynik operacji splotu danej cechy Źródło: Opracownie własne



Rysunek 1.11. Przykład warstwy konwolucyjnej dla litery k Źródło: Opracownie własne


Kolejnym narzędziem oferowanym przez CNN jest warstwa sumowania (ang. pooling layer). Pooling daje możliwość zmniejszenia dużych obrazów bez utraty ważnych informacji na ich temat. Operacje wykonywane w tej warstwie to podział zdjęcia z poprzedniej warstwy na mniejsze, a następnie pobranie maksimum z danej części. Operacje te należy powtórzyć na całym zdjęciu.



Rysunek 1.12. Przykład sumowania Źródło: Opracownie własne

Po sumowaniu, wielkość danego zdjęcia jest cztery razy mniejsza. Ponieważ przetrzymywane są wartości maksymalne z każdego okna, przechowywane zostają najlepsze pasujące wartości danej cechy w oknie. To oznacza, że nie ważne jest gdzie dana cecha pasuje do momentu, aż znajdziemy pasującą odpowiedź w oknie.

Dodatkowym narzędziem jest warstwa normalizacyjna (ang. Rectified Linear Units Layer, ReLU), użycie tej funkcji pozwala ustawić wszystkie ujemne wartości liczbowe na zero. Jeśli wartość jest większa od zero, funkcja ReLU zwróci jeden. To ważny proces w którym wszystkie ujemne wartości zostają zastąpione zerami. Wspomaga to funkcjonowaniu sieci trzymając wszystkie wartości na których wykonywane są operacje by te były równe o lub dodatnie.

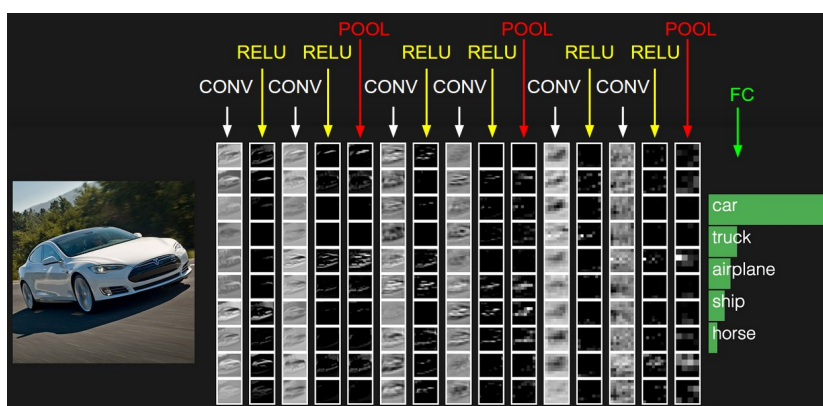


Rysunek 1.13. Przykład normalizacji danych Źródło: Opracownie własne

Ostatnią warstwą sieci z możliwych do wykorzystania jest warstwa FCL (ang. Fully Connected Layer) jak sama nazwa wskazuje, zadaniem tego poziomu sieci jest połączenie otrzymanych wyników w poprzednich fazach, czyli faz Splotu, Pooling oraz ReLU. Wynikiem połączenia jest tablica wartości z przedziału od 0 do 1.

W zaprezentowanym przykładzie problemem do rozwiązania jest zadane pytanie: Do jakiej kategorii należy znak A przedstawiony na obrazku, X czy O?

Warstwa FCL zbudowana jest z wielu tradycyjnych sieci neuronowych. Zamiast traktować wejście sieci jako dwuwymiarowe tablice, wykorzystywane są tablice jednowymiarowe. Każda wartość otrzymuje końcowy wynik określający czy na zdjęciu przedstawione jest X - w takim wypadku wynik byłby równy 1 lub w przeciwnym wypadku kiedy końcowy wynik jest równy 0 w tym wypadku odpowiedzią zwróconą przez model jest litera O.



Rysunek 1.14. Klasyfikacja przykładowego obrazu Źródło:

<http://cs231n.github.io/convolutional-networks/>

Podsumowując klasyfikacja przebiega następująco:

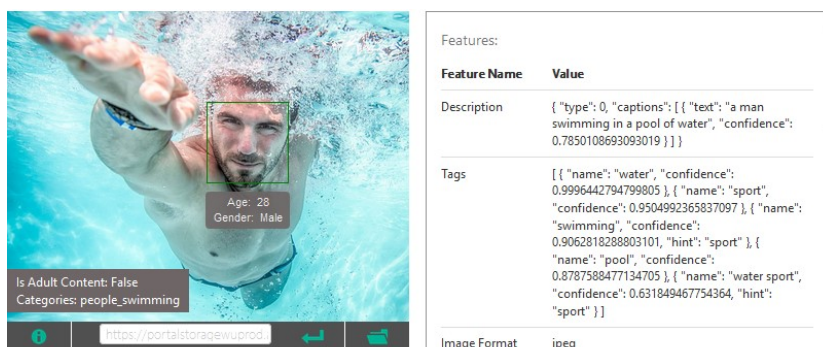
- Stwórz pierwszą warstwę splotu sieci i wyznacz 10 cech (ang. feature) przykładowego zdjęcia,
- Wykonaj ReLU, znormalizuj dane,
- Następnie wykonaj krok 1 i 2 ponownie,
- Przeprowadź sumowanie. Zmniejsz wielkość cech,
- Kolejnym etapem jest wykonanie kroków od 1 do 4 dwukrotnie,
- Po trzykrotnym wykonaniu operacji Pooling, stwórz warstwę FCL i podaj zaproponowane rozpoznania.

Przegląd bibliotek uczenia maszynowego

Aby dobrze zobrazować problem rozpoznawania pisma odręcznego w aplikacjach mobilnych, wykorzystanych zostało kilka technologii oraz bibliotek dostępnych w językach programowania Python oraz C#. Jednocześnie wybrane przykłady demonstrują gotowe implementacje algorytmów, które pozwalają wykorzystywać uczenie maszynowe do własnych potrzeb bez koniecznej wiedzy z zakresu uczenia maszynowego, takimi technologiami są Microsoft Computer Vision[9] oraz TesseractAPI[10]. Drugim przykładem są biblioteki dostępne do użycia dla programistów uczenia maszynowego, pozwalające na precyzyjne skonfigurowanie dostępnych algorytmów do własnych potrzeb, są to biblioteki Scikit-learn oraz Tensorflow. Dodatkowo, wykorzystana została biblioteka EmguCV pozwalająca na wykrywanie znaków na zdjęciach oraz odpowiednie formatowanie go na potrzeby stworzenia modelu danych do treningu.

2.1. Microsoft Computer Vision API

Usługi Microsoft Cognitive Services[9] umożliwiają kompilowanie aplikacji z awansowanymi algorytmami przy użyciu zaledwie kilku wierszy kodu. Działają one na różnych urządzeniach i platformach, takich jak systemy iOS, Android i Windows, wciąż są ulepszone i łatwo je skonfigurować. Usług uruchomionych w ramach tego API jest dokładnie 22. Począwszy od lokalizowania twarzy na zdjęciach, rozpoznawania ich emocji, skończywszy na usłudze wykrywania tekstu na fotografiach, konwertowania mowy na tekst lub autosugestii wprowadzanego tekstu prosto z wyszukiwarki Bing.



Rysunek 2.1. Przykładowa aplikacja implementująca Computer Vision API Źródło:

<https://www.programmableweb.com/sites/default/files/microsoft%20computer%20vision%20API.jpg>

Computer Vision API, jest system bazowanym na rozwiązaniach Azure, dostarcza deweloperom dostęp do algorytmów pozwalających na przetwarzanie obrazów i zwracanie informacji na ich temat. Poprzez wysłanie obrazu do serwera algorytmy umieszczone w chmurze firmy Microsoft są w stanie zanalizować kontekst wizualny w wielu różnych sposobach na podstawie wyborów użytkowników.

Computer Vision API, jest system opartym na rozwiązaniach chmurowych firmy Microsoft - Azure. Dostarcza deweloperom dostęp do algorytmów pozwalających na przetwarzanie obrazów i zwracanie informacji na ich temat. Poprzez wysłanie obrazu do serwera algorytmy umieszczone w chmurze firmy Microsoft są w stanie zanalizować kontekst wizualny w wielu różnych sposobach na podstawie wyborów użytkowników.

Między innymi technologia zawiera narzędzia do rozpoznawania znaków oraz całych tekstów. Działa ona w 21 językach, dostępny jest również język polski. Usługa posiada możliwość dostosowania kąta nachylenia tekstu, horyzontalnego obrotu osi by rozpoznania dawały lepszy efekt.

Skuteczność rozpoznanego tekstu zależy od jakości zdjęcia. Nie dokładne rozpoznania mogą być spowodowane dostarczeniem zdjęcia które:

- Zawiera odręczne pismo
- Jest rozmazane lub czcionka tekstu jest rzadko spotykana

- Posiada złożone tła, cienie, odbicia na tekście

Od marca 2017r. technologia ta pozwala na rozpoznawanie ręcznie pisanego tekstu w języku angielskim, dostępna jest ona w wersji demonstracyjnej i rozpoznaje jedynie zdjęcia w języku angielskim.

2.2. TesseractAPI

Tesseract silnikiem służącym do rozpoznawania znaków, dostępny jest on na oficjalnej stronie[10], biblioteka udostępniana jest na zasadzie wolnych źródeł. Może być on używany bezpośrednio lub używając API by wyodrębnić napisane odręcznie bądź też drukowane znaki ze zdjęć. Obsługuje on ponad 20 języków w tym też Polski.

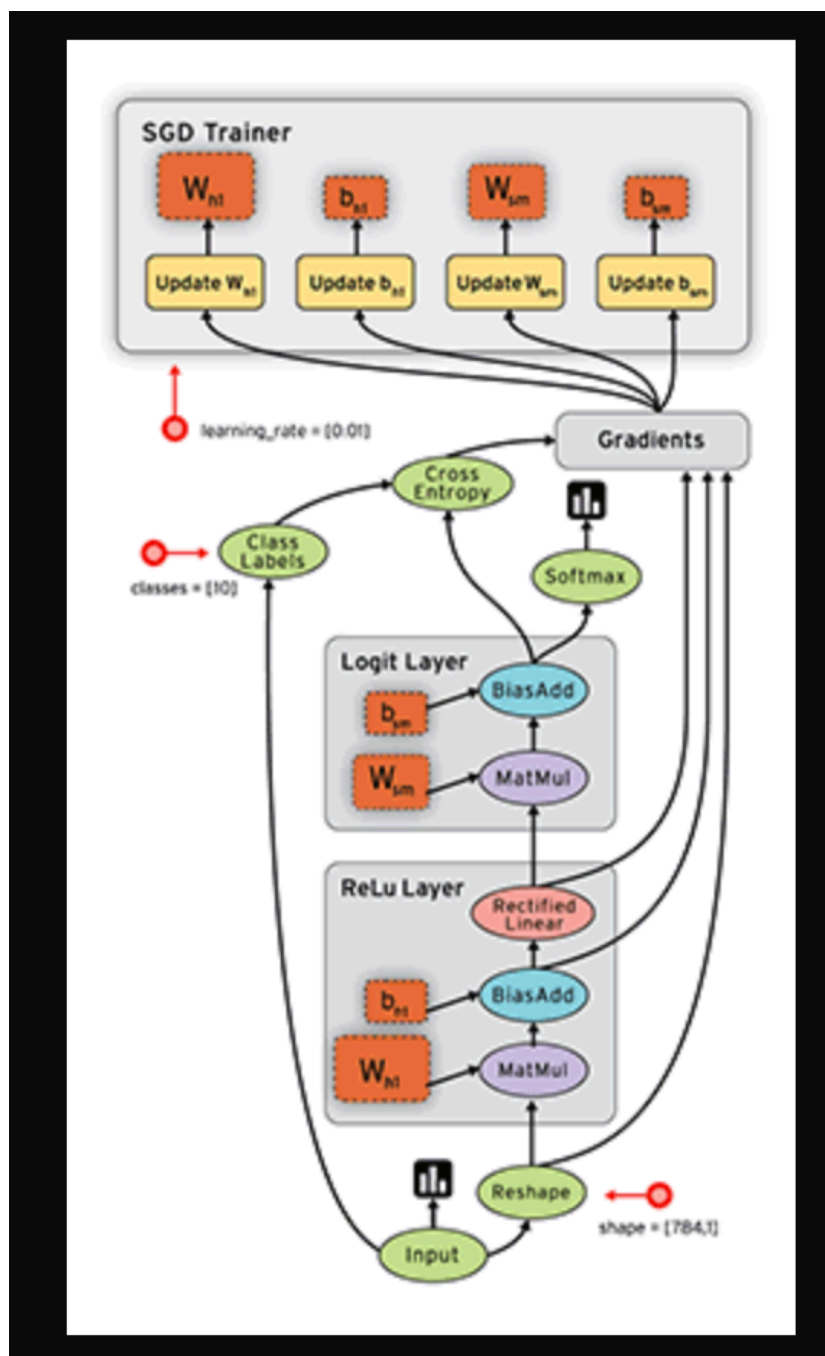
Zaletą dostępnego API jest prosta obsługa, brak konieczności posiadania wiedzy z zakresu modelowania algorytmów do uczenia maszynowego oraz gotowe modele języka, które dostępne są do pobrania na stronie projektu.

Wadami tego systemu jest brak możliwości ingerencji w model danych, którymi dysponuje API, nie ma możliwości modyfikacji algorytmów, które wykorzystywane są do rozpoznawania znaków. Skutkuje to niską skutecznością rozpoznania znaków pisma odręcznego.

2.3. TensorFlow

Najważniejsze komponenty TensorFlow[16], stworzonej przez Google biblioteki sztucznej inteligencji, która głównie wykorzystywana jest do rozpoznawania obrazów i mowy, maszynowych tłumaczeń oraz dostarczania lepszych wyników wyszukiwania w danych, biblioteka jest otwarta i udostępniona na wolnej licencji Apache 2.0.

Działanie TensorFlow przypomina sposób wykonywania obliczeń za pomocą grafu skierowanego, w którym wierzchołki to matematyczne operacje lub punkty, w których dochodzi do wymiany danych, zaś krawędzie opisują relacje wejścia i wyjścia pomiędzy węzłami, przedstawione w formie dynamicznych macierzy danych, czyli tensorów.



Rysunek 2.2. Graf przedstawiający działanie TensorFlow Źródło:

<https://kimschmidtsbrain.files.wordpress.com/2015/10/tensorflow-flow.jpg>

Biblioteka oferowana przez firmę Google pozwala na obliczenia numeryczne z wykorzystaniem takich grafów. Można tu korzystać z ogromnych klastrów superkomputerowych, stacji roboczych z wieloma procesorami graficznymi, a nawet wielordzeniowych mobilnych procesorów w smartfonach.

W badaniach nad problemem rozpoznawania znaków, biblioteka TensorFlow została użyta by stworzyć Splotową Sieć Neuronową, ponieważ sposób wykonywania operacji na macierzach, elastyczność oraz bogata dokumentacja pozwalają na proste zamodelowanie sieci, która przy dużej skuteczności potrafi rozpoznać litery i cyfry pisane odręcznie.

2.4. Scikit-learn

Scikit-learn[17] is biblioteką dostępną w języku Python, służy ona do uczenia maszynowego, oferuje ona szereg algorytmów uczenia szynowego. Biblioteka zbudowana jest na podstawie SciPy, który jest wymagany elementem do instalacji i używania scikit-learn. W stos SciPy wchodzi biblioteki:

- NumPy - dostarcza on n-wymiarowe tablice
- SciPy - służy do wykonywania obliczeń naukowych
- Matplotlib - narzędzie do rysowania grafów 2D/3D
- Pandas - struktury oraz analiza danych

Celem autorów biblioteki było dostarczenie solidnego i dobrze wspomaganego przez społeczność zestawu narzędzi, które działałyby na systemach produkcyjnych. To oznacza, prostota, jakość kodu, dokumentacja oraz wydajność biblioteki jest bardzo wysoka.

Scikit-learn oferuje dużą liczbę klasyfikatorów takich jak:

- Algorytm k najbliższych sąsiadów
- Drzewa decyzyjne
- Random forrest

- Regresja liniowa
- Sieci neuronowe

Na ten moment, biblioteka nie oferuje wsparcia dla własnych modeli sieci neuronowych oraz wykorzystywania klastrów procesorów graficznych.

2.5. EmguCV

EmguCV[18] jest wieloplatformową implementacją biblioteki OpenCV służącą do przetwarzania zdjęć. Pozwala ona na wywoływanie funkcji OpenCV z poziomu .NET i językami, które są wspierane takie jak C#, VC++, IronPython czy F#. Implementacja ta może być skompilowana z poziomu Visual Studio, Xamarin Studio oraz Unity. Działa na platformach Windows, Linux, Mac OS X, iOS, Android oraz Windows Phone.

Zaletami użycia EmguCV jest przede wszystkim możliwość implementacji na wielu platformach używając jednej technologii, gdyż EmguCV jest napisana w języku C#. To oznacza że może być kompilowana za pomocą Mono, czyli kompilatora C# dostępnego pod platformami Linux oraz Mac OS X. Dzięki temu, przy użyciu platformy Xamarin oraz EmguCV, wszystkie operacje związane z obróbką zdjęcia i przygotowaniem go do klasyfikacji, mogą zostać wykonane z poziomu aplikacji, jest to ważny aspekt, gdyż w wypadku ograniczonych zasobów, koszt przygotowania zdjęcia do klasyfikacji jest duży.

Przeprowadzone badania

Aby przeprowadzić badania wskazujące czy przedstawiona propozycja konwulucyjnej sieci neuronowej autora osiąga lepsze wyniki rozpoznania od innych opisanych w pracy istniejących rozwiązań, stworzona została wieloplatformowa aplikacja mobilna, która po narysowaniu dowolnego znaku lub cyfry podejmuje próbę rozpoznania. Porównane zostaną implementacje Microsoft Computer Vision API[9], TesseractAPI[10] oraz Webservice'u[5] stworzonego przez autora, który rozpoznawanie określa na podstawie modelu sieci CNN[14].

Podjęta zostanie również próba porównania treningu modeli o różnym rozmiarze jednego znaku, punktem wejściowym do pomiaru będzie pełny model danych, ok. 1.5mln zdjęć cyfr i liter, przedstawione zostaną warianty tego modelu posiadające inną liczbę elementów, bądź inny rozmiar zdjęć.

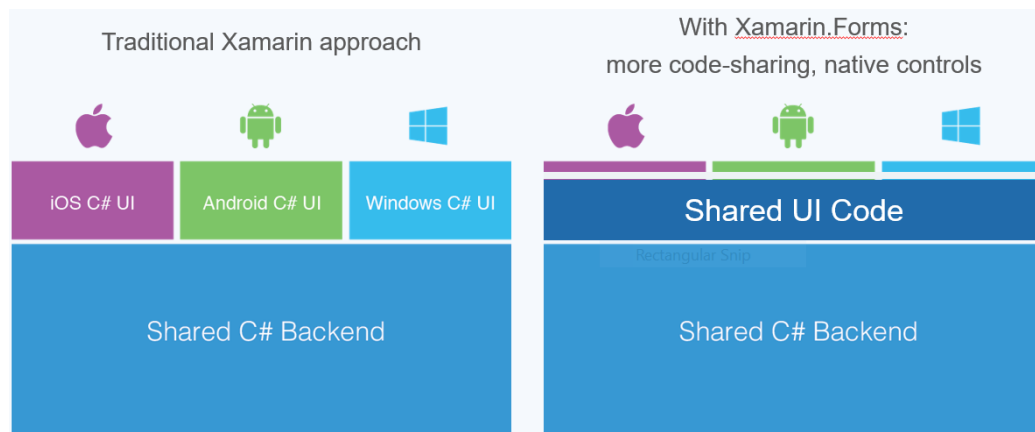
3.1. Xamarin

Xamarin[15] pozwala na tworzenie natywnych aplikacji Android/iOS z wykorzystaniem języka C# i platformy .NET. Same aplikacje tworzymy w Visual Studio lub Xamarin Studio, a możemy do tego podejść na dwa sposoby: Xamarin.Native lub Xamarin.Forms (więcej o tych dwóch podejściach będzie w dalszej części posta). Xamarin od zeszłego roku jest dostępny dla wszystkich zainteresowanych, dzięki jego przejściu przez Microsoft. Natomiast, sam kod źródłowy Xamarina został udostępniony na GitHub.

Kompilator Xamarin.iOS kompiluje AOT(ang. Ahead-of-time) aplikacje do natywnego kodu dla ARM, który jest uruchamiany bezpośrednio na iPhone'ach. Natomiast kompilator Xamarin.Android kompiluje do języka IL (Intermediate Language), następnie by uruchomić aplikację, korzysta z JIT (ang. Just-in-time).

Dzięki tym zabiegom, Xamarin jest transparentny dla docelowych systemów mobilnych, tworząc natywne, w pełni funkcjonalne aplikacje.

W Xamarin.Forms[6] można pisać kod na dwa sposoby, w tzw. code behind w C# lub za pomocą XAML. Drugi sposób dla osób z doświadczeniem w WPF jest bardzo wygodnym rozwiązaniem. Xamarin.Forms tzw. warpery na natywne kontrolki. Oznacza to, że np. odwołując się do kontrolki Label w Formsach odwołujemy się do ich natywnych odpowiedników w poszczególnych platformach pisząc tylko jeden kod. Ponadto kontrolki Xamarin.Forms są w pełni edytowalne i konfigurowalne tzn. w przypadku gdy czegoś brakuje, można poszukać gotowego rozwiązania lub stworzyć własne.



Rysunek 3.1. architektura platformy Xamarin Źródło:

<https://dab1nmslvvntp.cloudfront.net/wp-content/uploads/2016/02/1456296251XamVsXF.png>

3.2. Zbiór testowy

W uczeniu maszynowym istnieje wiele metod testowania skuteczności klasyfikatorów. W pracy zawarto metodę losowego podziału na zbiory treningowe i testowe. Oznacza to, iż zbiór danych jest dzielony na dwie części. Uczenie klasyfikatora przebiega z wykorzystaniem zbioru treningowego, natomiast w celu sprawdzenia generalizacji klasyfikatora wykorzystywana jest testowa część danych[19]. Metoda ta wydaje się być najbardziej zbliżona do rzeczywistości. Wadą w tym wypadku jest ograniczenie ilości danych treningowych, co w przypadku, gdy do dyspozycji jest niewielka liczba próbek lub występują ograniczenia sprzętowe, prowadzi do pogorszenia skuteczności klasyfikatora.

3.3. Skuteczność klasyfikacji

Używając zbioru treningowego stworzonego za pomocą narzędzia przedstawionego w sekcji 1.2 oraz klasyfikatorów problemu rozpoznania znaków pisma odręcznego wybranych w rozdziale pierwszym przeprowadzone zostaną badania wykorzystujące algorytmy wymienione w sekcjach 1.3, 1.4 oraz sieci neuronowe 1.5, 1.6. Badanie zostało oparte o zbiór testowy zawierający 3600 elementów, uzyskane zostały następujące rezultaty:

Nazwa	Dokładność
kNN	60%
Random Forest	50%
Sieć neuronowa	91%
CNN	95%

Tabela 3.1. Wyniki badań skuteczności klasyfikatorów

Następnie używając zbioru testowego z poprzednich badań wykonane zostało porównanie rozpoznania aplikacji korzystających z gotowych bibliotek

Według wyników badań, najlepszą metodą klasyfikacji znaków pisma odręcz-

Nazwa	Dokładność
Computer Vision API	29%
Tesseract API	32%

Tabela 3.2. Wyniki badań skuteczności klasyfikatorów

nego jest wykorzystanie konwolucyjnych sieci neuronowych proponowanych przez autora.

3.4. Czas treningu

Używając zbioru treningowego stworzonego za pomocą narzędzia przedstawionego w sekcji 1.2 oraz klasyfikatorów problemu rozpoznania znaków pisma odręcznego wybranych w rozdziale 1 przeprowadzone zostaną badania wykorzystujące algorytmy wymienione w sekcjach 1.3, 1.4 oraz sieci neuronowe 1.5, 1.6. Badanie zostało oparte o zbiór testowy zawierający 3600 elementów, uzyskane zostały następujące rezultaty:

Nazwa	Czas(sekundy)
kNN	12.3
Random Forest	9
Sieć neuronowa	159
CNN	3969

Tabela 3.3. Wyniki badań czasu treningu klasyfikatorów

Testy zostały przeprowadzone na komputerze MacBook Pro (Retina, 13-inch Early 2015), procesor 2,7 GHz Intel Core i5, pamięć 8GB 1867MHz DDR.

Badanie bibliotek uczenia maszynowego zostało pominięte ze względu na to, iż w procesie nie występuje etap treningu.

3.5. Porównanie modeli danych

W celu przeprowadzenia porównania modeli danych treningowych problemu rozpoznawania polskich znaków pisanych utworzono pięć różnych zbiorów danych, każdy z nich posiada określoną ilość elementów każdego znaku oraz rozdzielczość w jakiej zapisano poszczególne obrazy. Badanie ma na celu sprawdzenie czy w warunkach mocno ograniczających przeprowadzanie treningu modelu, np. na urządzeniach mobilnych, istnieje znacząca różnica w wynikach danych. Trening przeprowadzono korzystając proponowaną przez autora splotową sieć neuronową, ponieważ rezultaty w poprzednich badaniach pokazały, iż pokazuje ona najlepsze parametry wymagane do przeprowadzenia takiego testu.

Model	Ilość elementów	Rozdzielczość
1	72000	28 x 28 pikseli
2	250000	28 x 28 pikseli
3	500000	28 x 28 pikseli
4	750000	28 x 28 pikseli
5	125000	32 x 32 pikseli

Tabela 3.4. Dane wejściowe - porównanie modeli danych

Wyniki treningu poszczególnych modeli, dla liczby iteracji równej 5000, do testu skuteczności został użyty zbiór testowy używany w poprzednich badaniach. Skuteczność przedstawiona w wynikach testu to procent prawidłowej klasyfikacji przy użyciu zbioru testowego.

Badanie bibliotek uczenia maszynowego zostało pominięte ze względu na to, iż w procesie nie występuje etap treningu.

3.6. Rozmiar modelu, a skuteczność terningu

Z przeprowadzonych badań wynika, iż skuteczność treningu w jakimś stopniu zależy od ilości danych zawartych w zbiorze treningowym. Wszystkie porównania przeprowadzane były w warunkach domowych co oznacza duże ograniczenia

Model	Skuteczność	Czas treningu
1	90%	1h 32m
2	88%	4h 51m
3	94%	6h 02m
4	—	—
5	92%	2h 42m

Tabela 3.5. Wyniki - porównanie modeli danych

zasobów pamięci RAM, CPU oraz GPU. Trening na największym zbiorze danych nie był w stanie uruchomić się na środowisku testowym ponieważ zasoby potrzebne na operacje na macierzach wykonywane są w pamięci RAM, która jest znacznie ograniczona.

Jednak z obserwacji wynika, iż im bardziej precyzyjne zawarte są dane w modelu, trening sieci neuronowych rezultuje lepszym wynikiem końcowym.

Małe modele danych, czyli takie, których trening oparty był na zbiorze treningowym o małej ilości elementów idealne są do celów sprawdzenia czy istnieje poprawa jakości wyodrębnionych cech poszczególnych obrazów i czy klasyfikacja zbioru testowego pokaże lepsze wyniki.

Podsumowanie i wnioski

Otrzymane wyniki przez autora pokazują przewagę sieci neuronowych nad algorytmami z klasy regresji nieparametrycznej lub teorii decyzji. Jeśli rozpatrywany jest model danych zawierający duży zbiór informacji, należy go odpowiednio przygotować, aby zawarte w nim właściwości jak najbardziej nadawały się do przetworzenia przez klasyfikator.

Również ważnym aspektem uczenia maszynowego jest posiadany sprzęt na który klasyfikatory będą przeprowadzały trening modelu. Proces przebiegu treningu na domowym laptopie jest znacznie gorszy, niż na profesjonalnym serwerze zaopatrzonym w technologie CUDA, czyli karty graficzne oferujące możliwość wykonywania obliczeń równoległych, które utylizują moc oferowaną przez procesory graficzne, w przeciwnym razie modele podczas treningu zapisywane są w pamięci podręcznej systemu, która przy dużym rozmiarze modelu, często przepełnia się. Efektem tego jest zmarnowany czas oraz zasoby.

OCR (ang. Optical Character Recognition) jest to technika lub część oprogramowania służąca do rozpoznawania znaków oraz całych tekstów zapisanych w pliku graficznym prezentowanym za pomocą pionowo-poziomej siatki odpowiednio kolorowanych pikseli. Przykładem takiej grafiki jest zdjęcie z aparatu cyfrowego.

4.1. Uczenie maszynowe w aplikacjach mobilnych

Wykorzystywanie technik uczenia maszynowego, czy to są algorytmy typu random forrest, czy też sieci neuronowe, wymagają olbrzymich zasobów sprzętowych, w związku z tym urządzenia mobilne, których moc obliczeniowa nie może równać się z komputerami klasy PC czy klastrów procesorów graficznych nie nadają się do treningów. Istniejące gotowe rozwiązania jak na przykład przedstawione w pracu usługi Cognitive Services od firmy Microsoft idealnie pasują do rynku aplikacji

mobilnych, ponieważ wszystkie obliczenia związane z klasyfikacją znajdują się po stronie serwera, wadą tego rozwiązania jest natomiast brak ingerencji w modele danych oraz brak jakiejkolwiek personalizacji, który mógłby pomóc w rozwiązaniu problemu.

Idealnym rozwiązaniem, również wykorzystanym w tej pracy przez autora jest połączenie mocy obliczeniowej komputerów PC lub laptopów by wytrenować odpowiedni model danych realizujący problem, a następnie stworzenie aplikacji webowej, która implementowałaby określony interfejs, tak aby była możliwość konsumowania go po stronie aplikacji mobilnej. W ten sposób zyskujemy nie zawodność po stronie mobilnej oraz personalizację i wgląd w model danych po stronie serwera.

4.2. Najlepsza metoda rozpoznawania pisma odręcznego

W pracy przedstawionej przez autora zostało zaprezentowanych kilka metod klasyfikacji danych problemu rozpoznawania znaków pisma odręcznego oraz dwie biblioteki umożliwiające błyskawiczne rozpoznanie obrazka bez konieczności posiadania specjalistycznej wiedzy z zakresu uczenia maszynowego. Według badań zawartych w rozdziale 3, najlepszym istniejącym sposobem rozwiązania zadanego przez autora problemu jest wykorzystanie konwolucyjnych sieci neuronowych. Model danych odgrywa najważniejszą rolę przy podejmowaniu próby klasyfikacji znaków pisma odręcznego, gdyż elementy w nim zawarte powinny jak najbardziej odzwierciedlać rzeczywiste cechy liter oraz cyfr.

4.3. Zalety aplikacji wieloplatformowych

- Xamarin bazowo unifikuje przede wszystkim serwerową część aplikacji. Jeśli stworzymy aplikację z rozbudowaną logiką biznesową, to warto ją pisać tylko raz. Xamarin na pewno w tym pomoże
- Jeśli layout aplikacji opiera się o standardowe elementy i wzorce, to warto

użyć Xamarin.Forms, który obsługuje kilkadziesiąt kontrolek, które później mapowane są na natywne rozwiązania

- Jeśli konieczne jest posiadanie osobnego zestawu programistów na każdą platformę, to również warto dać szansę Xamarinowi. Nawet podejście natywne można w całości napisać w języku C#. Xamarin mapuje 100% API z platform Android oraz iOS
- Jeśli programista posiadał doświadczenie z jakąkolwiek technologią operującą na XAMLu (WPF, Silverlight, Universal Apps, UWP), to również w tej sytuacji nie powinien mieć problemów z programowaniem w Xamarin.Formsie
- Pod Xamarina można programować w Visual Studio [Community] dla Windows lub Xamarin Studio dla OS X
- Kod źródłowy całego rozwiązania dostępny jest na GitHubie

4.4. Wady aplikacji wieloplatformowych

- Podejście Forms zazwyczaj nie pozwala na napisanie całej aplikacji. Część kodu i tak musi być pisana z użyciem dedykowanych konstrukcji warunkowych, a w przypadku złożonych interfejsów, może to być większa część kodu
- Do pracy z Xamarinem wymagana jest również przynajmniej bazowa znajomość C#. W podejściu Xamarin.Forms, trzeba się również nauczyć XAMLa.
- Ponadto przy wydaniu każdej nowej wersji wspieranych systemów, należy czekać wrappery. Oczywiście w chwili obecnej pojawiają się one praktycznie natychmiast, ale pytanie czy tak będzie zawsze?
- Xamarin bywa również niestabilny. Zdarzają się wersje lepsze i gorsze. Czasami pojawiają się problemy w sytuacji gdy odpalamy solucję przygotowaną w Visual Studio na Macu i odwrotnie. Zdarzają się również inne błędy.

Zakończenie

Problem OCR (ang. Optical Character Recognition) należy do jednej z najbardziej popularnych grup w branży zgłębiania danych i uczenia maszynowego. Dzięki gotowym bibliotekom, które oferowane są przez firmy takie jak Microsoft lub Amazon pozwalają programistom na budowę funkcjonalności w swoich programach, które wykonują rozpoznanie znaków w czasie rzeczywistym bez potrzeby pozyskiwania specjalistycznej wiedzy na temat algorytmów oraz sieci neuronowych. Natomiast, jeśli rozpatrywany jest konkretny przypadek np. problem rozpoznawania znaków pisma odręcznego, istniejące rozwiązania mogą nie być wystarczające, ponieważ osiągnięte przez nie wyniki są zbyt niskie by stosować je na środowiskach produkcyjnych.

Celem pracy autora było zaprezentowanie istniejących rozwiązań pozwalających szybko przeprowadzenie rozpoznania znaków pisma odręcznego oraz przedstawienie własnej implementacji sieci neuronowej, która rozwiązuje problem należący do tej samej klasy.

Wynikiem pracy jest webservice dostępny do użytku ogólnego oraz aplikacja wieloplatformowa, która pozwala sklasyfikować dowolną literę bądź cyfrę. Skuteczność wytworzonego modelu na podstawie propozycji sieci neuronowej autora znacząco poprawia istniejące implementacje dostępne do użytku. Cel pracy został zrealizowany.

Cel pracy, czyli przedstawienie własnego rozwiązania, mogącego posłużyć do rozpoznawania znaków pisma odręcznego w formularzach, został zrealizowany. Autor pracy zamierza rozszerzyć funkcjonalność zawartą w publikacji, aby mogła ona posłużyć rozpoznawaniu pisma na różnego rodzaju formularzach.

Bibliografia

- [1] Brandewinder, Mathias, 2015, Machine Learning Projects for .NET Developers, Apress, ISBN: 978-1-4302-6766-9.
- [2] M. Narasimha, Murty, 2015, Introduction to pattern recognition and machine learning, World Scientific Publishing Co. Pte. Ltd, ISBN: 978-9-814-33545-4 .
- [3] Kirk, Matthew, 2015, Thoughtful Machine Learning, O'Reilly, ISBN: 978-1-449-37406-8.
- [4] Troelsen, Andrew, 2011, Język C# 2010 i platforma .NET 4, PWN, ISBN: 978-83-01-16666-3.
- [5] Norton, Peter, Samuel, Alex, Aitel, David, 2005, Od podstaw Python, Wydawnictwo HELION, ISBN: 83-246-0528-2.
- [6] Petzold, Charles, 2016, Creating Mobile Apps with Xamarin.Forms, Microsoft Press, ISBN: 978-1-5093-0297-0.
- [7] <https://www.nist.gov/srd/nist-special-database-19> (Dostęp 22 maja 2017r.)
- [8] <https://github.com/mathias-brandewinder/machine-learning-projects-for-dot-net-developers> (Dostęp 22 maja 2017r.)
- [9] <https://azure.microsoft.com/en-us/services/cognitive-services/> (Dostęp 22 maja 2017r.)
- [10] <https://github.com/tesseract-ocr/tesseract> (Dostęp 22 maja 2017r.)
- [11] <http://shyamalapriya.github.io/digit-recognition-using-k-nearest-neighbors/>, (Dostęp 22 maja 2017r.)
- [12] <http://neuralnetworksanddeeplearning.com/chap1.html>, (Dostęp 22 maja 2017r.)

- [13] <http://deblivingdata.net/machine-learning-the-digit-recognition-problem/>,
(Dostęp 22 maja 2017r.)
- [14] <http://cs231n.github.io/convolutional-networks/>, (Dostęp 22 maja 2017r.)
- [15] <https://www.xamarin.com/platform>, (Dostęp 22 maja 2017r.)
- [16] https://www.tensorflow.org/api_docs/, (Dostęp 22 maja 2017r.)
- [17] <http://scikit-learn.org/>, (Dostęp 22 maja 2017r.)
- [18] http://www.emgu.com/wiki/index.php/Main_Page, (Dostęp 22 maja 2017r.)
- [19] <https://stats.stackexchange.com/questions/19048/what-is-the-difference-between-test-set-and-validation-set>, (Dostęp 22 maja 2017r.)
- [20] https://en.wikipedia.org/wiki/Optical_character_recognition, (Dostęp 22 maja 2017r.)

Oświadczenie

Ja, niżej podpisany(a) oświadczam, iż przedłożona praca dyplomowa została wykonana przeze mnie samodzielnie, nie narusza praw autorskich, interesów prawnych i materialnych innych osób.

.....

data

.....

podpis